

Análise de sentimentos em avaliações de clientes do
e-commerce nacional e comparação de métodos
tradicionais de *machine learning* com Redes Neurais
Long Short Term Memory (LSTM)

Carlos Magno Santos Ribeiro de Brito

TRABALHO DE CONCLUSÃO DE CURSO
APRESENTADO AO
INSTITUTO DE MATEMÁTICA E ESTATÍSTICA
DA
UNIVERSIDADE FEDERAL DA BAHIA
PARA
OBTENÇÃO DO TÍTULO
DE
ESPECIALISTA EM CIÊNCIA DE DADOS
E BIG DATA

Orientador: Prof. Dr. Eduardo Furtado de Simas Filho

Durante o desenvolvimento desta tese e curso o autor do presente trabalho foi contemplado
com uma bolsa para realização da especialização

Salvador, 21 de fevereiro de 2023

Análise de sentimentos em avaliações de clientes do *e-commerce* nacional e comparação de métodos tradicionais de *machine learning* com Redes Neurais *Long Short Term Memory* (LSTM)

Carlos Magno Santos Ribeiro de Brito¹

Eduardo Furtado de Simas Filho²

Resumo

Com o advento do coronavírus no mundo, o e-commerce e todo o comércio *on-line* no Brasil entre 2020 e 2021 se expandiu e se tornou ainda mais competitivo. Nesse contexto, identificar as necessidades dos consumidores e prever tendências de expansão de vendas é uma necessidade dos empreendedores no mercado atual para se tornar mais competitivo. Tendo como base isso, o presente trabalho objetivou analisar e comparar dados de diferentes E-commerces no Brasil com diferentes tipos de modelos conhecidos da ciência de dados, na intenção de que os negócios possam direcionar suas vendas de acordo com as preferências dos consumidores em diferentes nichos de mercados. Somando-se a isso, buscou-se indiretamente, desenvolver competências necessárias a prática profissional do cientista de dados, o qual projeta modelos e mecanismos de aprendizado orientados para os negócios e utiliza técnicas matemáticas para encontrar soluções de problemas de negócio ou científico.

Palavras chaves: E-commerce; Machine Learning; Redes Neurais Artificiais.

1 Introdução

O *E-commerce*, ou comércio eletrônico, pode ser definido como uma modalidade de negócio onde todo o processo de compra é feito exclusivamente online, isto é, em aplicativos móveis e computadores é realizado desde a escolha do produto ao pagamento. O comércio eletrônico como conhecemos hoje iniciou no final da década de 1960, mas desde 1993, novas tecnologias permitem as empresas realizar funções de negócios eletrônicos (e-business) com maior eficiência, rapidez e menores custos. Dados mais recentes da Associação Brasileira de Comércio Eletrônico (ABComm) estimam que, em 2020, 20,2 milhões de consumidores realizaram uma compra on-line pela primeira vez e 150 mil lojas começaram a vender por meio das plataformas digitais. Foram mais de 342 milhões de negociações feitas pela internet, com um valor médio de R\$310 e um volume financeiro estimado de R\$106 bilhões (Abcomm, 2020).

Até pouco tempo atrás as lojas virtuais eram utilizadas como plataforma de ampliação de vendas de lojas físicas já renomadas, à exemplo de Casas Bahia, Magazine Luiza, Lojas Americanas e etc., mas com a crescente do e-commerce no Brasil nos anos de 2020 e 2021, proveniente da crise do coronavírus, observa-se que as empresas estão apostando em lojas virtuais para a exposição e vendas dos seus produtos, dispensando, muitas vezes, o comércio em lojas físicas.

¹Universidade Federal da Bahia, carlos.ribeiro.brito@hotmail.com

²Departamento de Engenharia Elétrica e de Computação, eduardo.simas@ufba.br

Por se tratar de um mercado de acesso nacional, com maior eficiência, rapidez e menores custos, a ocorrência das vendas on-line é elevada. Logo, para uma empresa se manter competitiva e sólida neste mercado é preciso planejamento, inovação e, principalmente, entender sobre as necessidades dos clientes e como fidelizá-los. De acordo com [efagundes \(2021\)](#) um empreendimento de sucesso é aquele que consegue utilizar a tecnologia existente, adequada aos consumidores do seu nicho de mercado. Por isso mesmo, é fundamental conhecer o comportamento dos consumidores e as tendências do negócio.

No lado de quem consome, pode-se citar como vantagens do e-commerce: comodidade para os clientes, acesso a opinião de outros usuários/compradores, funcionamento em tempo integral, diversidade de produtos, variedade de opções de pagamentos, privacidade ao usuário/comprador, cupons de desconto e etc., e são justamente estas vantagens e diversidades de informações de dados na compra e venda de produtos que permitem identificar os nichos de mercados de cada seguimento.

Destarte, este trabalho objetivou analisar dados de diferentes *e-commerces* no Brasil, mais especificamente as notas e comentários avaliativos dados aos produtos comprados após o recebimento. Nesse processo foram concebidos modelos com quatro métodos tradicionais do aprendizado de máquina utilizados, sendo eles a Regressão logística, *Naive Bayes*, *XGBoost*, Florestas Aleatórias e, para fins comparativos analisou-se também um modelo construído com rede neural artificial *long short term memory* (LSTM).

2 Materiais e métodos

2.1 Tipo de pesquisa

Para realização deste trabalho, realizou-se uma pesquisa quantitativa descritiva, uma vez que buscou-se analisar dados de forma minuciosa a partir de Databases seccionados e coletados de diversas lojas virtuais no Brasil. Isto é, a pesquisa descritiva compreende a observação, ao registro, a análise, a classificação, a interpretação e a padronização de dados com a finalidade de explicar a correspondência entre as variáveis investigadas.

Em relação ao tratamento do problema, a pesquisa se caracterizou como quantitativa. Segundo [Malhotra \(2006\)](#), o objetivo da pesquisa quantitativa é quantificar os dados e aplicar ferramentas de análises estatísticas. O trabalho utilizou da tratativa, análise, correlação e apresentação de dados, além de aplicações de métodos estatísticos para criação de diferentes cenários, os quais têm como objetivo identificar possíveis tendência entre os dados utilizados e a satisfação do cliente na tomada de decisão em empresas que atuam nesse setor.

Quanto à coleta de dados, este trabalho foi classificado como uma pesquisa documental. A pesquisa documental recorre a fontes mais diversificadas e dispersas, sem tratamento analítico, tais como: tabelas estatísticas, jornais, revistas, relatórios, documentos oficiais, cartas, filmes, fotografias, pinturas, tapeçarias, relatórios de empresas, vídeos de programas de televisão, etc. ([da Fonseca, 2002](#)). A pesquisa documental é um tipo de pesquisa que é baseada dados e informações que não passaram por um processo analítico e/ou sintético. Os dados deste trabalho, de diferentes E-commerces no Brasil, foram disponibilizados pela Olist e estão disponíveis na plataforma *Kaggle*, com o nome *Brazilian E-Commerce Public Dataset* ([Olist and Kaggle, 2019](#)).

2.2 Fonte e descrição dos dados

Olist é uma startup brasileira que atua no segmento de E-commerce, sobretudo por meio de *marketplace*. De um lado, a Olist concentra vendedores que desejam anunciar em *mar-*

ketplaces como Mercado Livre, B2W, Via Varejo, Amazon e etc. Por outro, concentra os produtos de todos os vendedores em uma loja única que fica visível ao consumidor final. Atualmente o negócio reúne mais de 800 colaboradores e mais de 9 mil lojistas, além de 2 milhões de consumidores únicos (Olist, date).

A base de dados escolhida consiste em um conjunto de dados que descrevem a rotina de compra de um E-commerce. É possível visualizar diversas características de um produto, como o nome, preço, descrição, nota atribuída, comentários, local de compra, etc. Mais especificamente, para este trabalho, analisou-se os comentários avaliativos (*review comment message*) e as notas dadas pelos clientes (*review score*).

2.3 Ferramentas

Abaixo na Figura 1, tem-se o fluxograma do processo de realização deste trabalho




Figura 1: Fluxograma do trabalho

O esquema dos *databases* disponibilizados pelo Olist é representado na Figura 2. Nele, utilizou-se apenas a tabela *olist_order_review*, com os campos disponíveis na Tabela 1.




Figura 2: Esquemas do dataset publicado pelo Olist, adaptado pelo autor (2022)

	review_id	order_id	review_comment_title	review_comment_message	
type	hash	hash	string—null	string—null	...
ex	da79b0a377eb	df73dbeba33	bom, mas	atende às expectativas	

	review_score	review_creation_date	review_answer_timestamp
type	number	datestring	datestring
ex	3	2018-01-18 00:00:00	2018-01-18 21:00:00

Tabela 1: Esquema da tabela *olist_order_review*

Na primeira fase, utilizando a linguagem de programação Python, os databases em formato CSV foram extraídos e exportados para leitura e armazenamento em diferentes variáveis no intuito de limpar e adequar os dados para análises. Nesta etapa, itens duplicados, com valores nulos e valores discrepantes foram removidos. Além disso, separou-se dois *datasets* contendo informações dos comentários dos clientes (*review_comment_message*) e da sua nota de avaliação (*review_score*). Para o *data_bin* tem-se comentários associados categoricamente com valores binários (0 e 1) a partir das notas, com o valor atribuído de 0 para o intervalo (0,2] e de 1 para o intervalo de (2, 5]. No *data_cat* tem-se apenas os comentários e os reviews numéricos de 1 a 5. Ambas as bases são removidos os valores nulos. Tem-se a Tabela 2 e Tabela 3 exemplificando os casos citados.

	index	text	label
type	bigint	string	boolean
exemplo	1	produto muito ruim	0

Tabela 2: Esquema de geração do *data_bin*

	index	text	label
type	bigint	string	number
exemplo	2	produto muito bom	4

Tabela 3: Esquema de geração do *data_gen*

2.4 Métodos

A partir das limpeza dos dados, para análise de ambos datasets gerados, lançou-se mão de métodos clássicos do *Machine learning* sendo eles: Regressão logística, Naive Bayes, Florestas Aleatórias e *XGBoost*. Além deles, para comparação, utilizou-se uma rede neural artificial LSTM. Esses métodos serão aqui melhor detalhados.

2.4.1 Regressão Logística

A regressão logística é um modelo estatístico robusto e eficiente, que permite a previsão da probabilidade de um evento binário de forma precisa e confiável (Hosmer Jr *et al.*, 2013). Este tipo de evento é aquele que pode ocorrer ou não, ou que pode ser classificado em duas categorias distintas. Por exemplo, em uma análise de crédito, o cliente pode ser aprovado ou não. Na medicina, o evento pode ser a cura ou não de uma doença.

Ela apresenta um modelo linear generalizado que utiliza a função logística para modelar a relação entre as variáveis independentes e a variável dependente (Kleinbaum and Klein,

2010). A função logística é uma função sigmoide que transforma uma variável linear em uma probabilidade. A equação da função logística é dada por:

$$p = \frac{1}{1 + e^{-x}} \quad (1)$$

Sendo p a probabilidade do evento ocorrer, x uma variável linear que representa a combinação linear das variáveis independentes, e e a constante de Euler.

A regressão logística utiliza a técnica de máxima verossimilhança para estimar os parâmetros do modelo a partir dos dados observados. A função de verossimilhança é maximizada para encontrar os valores dos coeficientes que melhor se ajustam aos dados. O modelo é ajustado para minimizar a diferença entre as probabilidades previstas pelo modelo e as probabilidades observadas nos dados (McCullagh and Nelder, 1989).

A regressão logística tem sido amplamente utilizada em diversas áreas, como na análise de dados de sobrevivência, na análise de dados de saúde, na análise de dados financeiros, etc. Por exemplo, é utilizada na análise de dados de sobrevivência para modelar a probabilidade de um paciente sobreviver a uma doença com base em fatores como idade, sexo, nível de educação, etc. Na análise de dados financeiros, é utilizada para modelar a probabilidade de um cliente pagar ou não uma dívida com base em fatores como histórico de crédito, renda, etc.




Figura 3: Modelo gráfico da regressão logística (curva sigmoide)

2.4.2 Naive Bayes

A classificação Naive Bayes é um algoritmo de aprendizado de máquina supervisionado que utiliza o teorema de Bayes para classificar instâncias em classes discretas. A principal vantagem do algoritmo Naive Bayes é a sua simplicidade e eficiência computacional, o que o torna uma escolha popular para problemas de classificação em grande escala (Mitchell, 1997).

O algoritmo Naive Bayes é baseado no teorema de Bayes, que fornece uma maneira de calcular a probabilidade condicional de uma hipótese, dado um conjunto de evidências. Na classificação, a hipótese corresponde à classe da instância e as evidências correspondem às características observadas da instância. O algoritmo calcula a probabilidade condicional de cada classe, dado as características observadas da instância, e atribui a instância à classe com a maior probabilidade condicional.

Segundo [Domingos and Pazzani \(1997\)](#), a principal suposição por trás do algoritmo Naive Bayes é a independência condicional das características, ou seja, cada característica contribui independentemente para a probabilidade condicional de cada classe. Embora essa suposição seja muitas vezes violada na prática, o algoritmo Naive Bayes ainda funciona bem em muitos casos e pode ser especialmente útil quando há muitas características.

O algoritmo Naive Bayes tem sido aplicado em muitas áreas, incluindo reconhecimento de fala, processamento de texto e detecção de spam de e-mail. É particularmente útil em aplicações onde há muitas características e as instâncias são discretas ou categóricas. Um estudo empírico sobre o desempenho do algoritmo Naive Bayes em diferentes conjuntos de dados pode ser encontrado em [\(Rish, 2001\)](#).

Embora o algoritmo Naive Bayes seja uma técnica de classificação simples e eficiente, ele também tem algumas limitações. Por exemplo, a suposição de independência condicional das características pode ser inadequada em algumas situações, e a performance do algoritmo pode ser afetada por dados ausentes ou dados ruidosos [\(Mitchell, 1997\)](#).

As equações abaixo representam a base matemática do algoritmo de classificação Naive Bayes:

Dada uma instância $X = x_1, x_2, \dots, x_n$ com características observadas, o objetivo do algoritmo é determinar a probabilidade condicional $P(C_k|X)$ da instância pertencer a cada classe C_k .

O teorema de Bayes fornece uma maneira de calcular a probabilidade condicional $P(C_k|X)$ em termos das probabilidades a priori $P(C_k)$ e das probabilidades condicionais $P(X|C_k)$, como segue:

$$P(C_k|X) = \frac{P(X|C_k)P(C_k)}{P(X)} \quad (2)$$

Aqui, $P(C_k)$ é a probabilidade a priori da classe C_k e $P(X|C_k)$ é a probabilidade condicional de observar a instância X dada a classe C_k .

O classificador Naive Bayes assume a independência condicional das características dadas a classe, isto é, $P(x_i|C_k, x_1, \dots, x_{i-1}, x_{i+1}, \dots, x_n) = P(x_i|C_k)$. Isso permite simplificar a probabilidade condicional $P(X|C_k)$ como:

$$P(X|C_k) = P(x_1, \dots, x_{i-1}, x_{i+1}, \dots, x_n|C_k) = \prod_{i=1}^n P(x_i|C_k) \quad (3)$$

Substituindo essa expressão na equação anterior, tem-se:

$$P(C_k|X) = \frac{\prod_{i=1}^n P(x_i|C_k)P(C_k)}{P(X)} \quad (4)$$

Como a probabilidade $P(X)$ é constante para todas as classes, é possível comparar apenas as probabilidades $P(C_k) \prod_{i=1}^n P(x_i|C_k)$ para determinar a classe mais provável para a instância X .

O desenho ilustra as variáveis aleatórias x_1, x_2, x_3, x_4 e a classe C_k . As setas que partem das probabilidades condicionais e a priori indicam as fórmulas para o cálculo das probabilidades conjuntas $P(x_1, x_2, x_3, x_4, C_k)$ e, conseqüentemente, para a classificação de uma instância.




Figura 4: Esquema de funcionamento da classificação Naive Bayes

2.4.3 Florestas aleatórias

De acordo com [Breiman \(2001\)](#), as florestas aleatórias são uma técnica de aprendizado de máquina que combina várias árvores de decisão para construir um modelo de classificação ou regressão. Cada árvore de decisão é construída a partir de um subconjunto aleatório dos dados de treinamento e um subconjunto aleatório dos recursos (também conhecidos como características ou atributos). Esses subconjuntos são criados para garantir que cada árvore de decisão seja diferente e que a floresta aleatória possa capturar várias relações entre os dados e recursos.

A construção de uma árvore de decisão é feita por meio de uma série de etapas. Inicialmente, a árvore começa com um único nó que representa todo o conjunto de dados de treinamento. Em seguida, a árvore é dividida em nós menores usando uma função de divisão que escolhe um recurso e um ponto de divisão que minimiza a impureza dos dados. A impureza é uma medida da desorganização dos dados, que pode ser medida por diferentes critérios, como a entropia ou o índice Gini. O processo de divisão é repetido recursivamente até que os nós finais sejam puros ou um critério de parada seja atingido, como uma profundidade máxima da árvore ([Cutler et al., 2001](#)).

Durante a fase de teste, a floresta aleatória retorna a classe mais comum ou a média das saídas das árvores individuais, dependendo se o problema é de classificação ou regressão, respectivamente.

As florestas aleatórias apresentam várias vantagens em relação a outras técnicas de aprendizado de máquina. Em primeiro lugar, elas têm um bom desempenho em dados de alta dimensão, onde o número de recursos é grande em relação ao número de amostras. Em segundo lugar, elas são relativamente insensíveis a outliers e dados ausentes. Em terceiro lugar, elas são facilmente paralelizáveis, permitindo que grandes conjuntos de dados sejam processados em paralelo em clusters de computadores ([Cutler et al., 2001](#)).

Em termos de aplicação, elas são amplamente utilizadas em uma variedade de problemas, como reconhecimento de padrões em imagens e sinais, detecção de fraudes em transações financeiras, análise de sentimentos em redes sociais, previsão de preços de ações e análise de dados genômicos ([Breiman, 2001](#)).

As equações relacionadas às florestas aleatórias são principalmente as usadas na construção de cada árvore de decisão. Por exemplo, as equações para o cálculo da impureza dos

dados, que é um dos principais critérios de divisão de nós em uma árvore de decisão são dadas:

- O índice Gini:

$$G_i = \sum_{k=1}^K p_{i,k}(1 - p_{i,k}), \quad (5)$$

onde K é o número de classes, $p_{i,k}$ é a proporção de observações da classe k no nó i .

- A entropia:

$$H_i = - \sum_{k=1}^K p_{i,k} \log(p_{i,k}), \quad (6)$$

onde K é o número de classes, $p_{i,k}$ é a proporção de observações da classe k no nó i .

- O critério de divisão de Gini é dado por:

$$G_d = \sum_{i=1}^q \frac{n_i}{n} G_i, \quad (7)$$

onde q é o número de nós filhos resultantes da divisão, n_i é o número de observações no nó i e n é o número total de observações.

- O critério de divisão de entropia é dado por:

$$H_d = - \sum_{i=1}^q \frac{n_i}{n} H_i, \quad (8)$$

onde q é o número de nós filhos resultantes da divisão, n_i é o número de observações no nó i e n é o número total de observações.

Essas equações são usadas para calcular a impureza dos dados em cada nó da árvore de decisão e, assim, decidir qual recurso e ponto de divisão usar para dividir o nó em dois filhos. O processo de divisão é repetido recursivamente para construir a árvore de decisão completa. Em seguida, várias árvores de decisão são combinadas para formar a floresta aleatória.

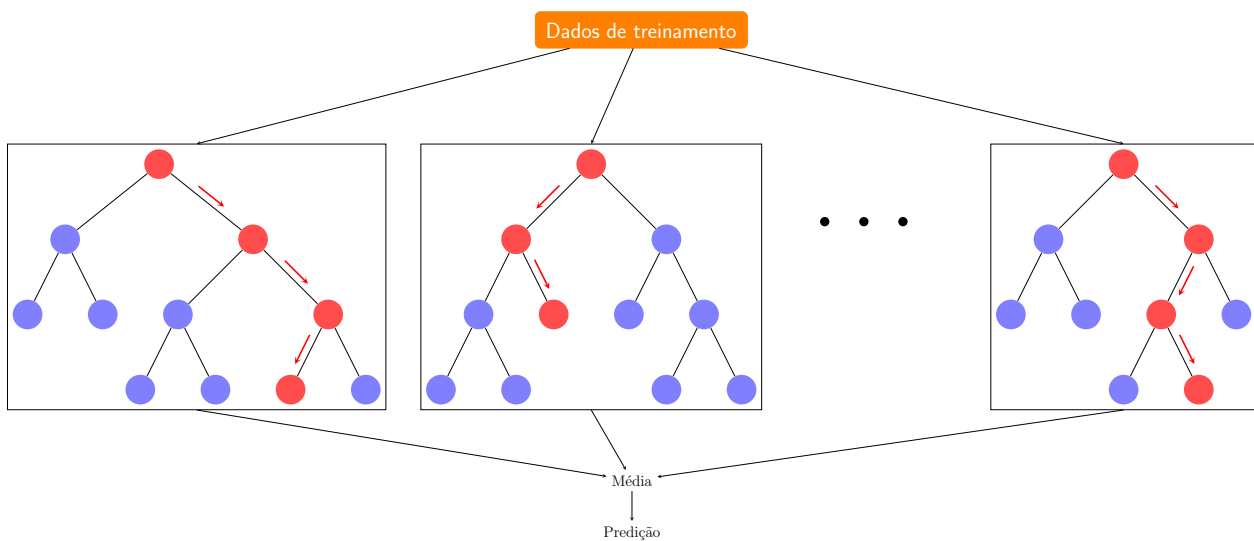


Figura 5: Esquema de funcionamento de uma floresta aleatória

2.4.4 XGBoost

O XGBoost (*Extreme Gradient Boosting*) é um método de aprendizado de máquina baseado em árvores de decisão, assim como as florestas aleatórias, mas com algumas diferenças importantes. Enquanto as florestas aleatórias usam um conjunto de árvores de decisão independentes para fazer uma previsão, o XGBoost usa um conjunto de árvores de decisão sequenciais que são criadas iterativamente. Cada nova árvore é ajustada aos resíduos do modelo anterior, tentando corrigir os erros cometidos pelo modelo atual.

O algoritmo XGBoost foi desenvolvido por Tianqi Chen e Carlos Guestrin em 2016 ([Chen and Guestrin, 2016](#)) e é baseado na biblioteca de código aberto de mesmo nome. O XGBoost se tornou um dos algoritmos de aprendizado de máquina mais populares em competições de ciência de dados e é amplamente utilizado na indústria.

O processo de construção do modelo XGBoost pode ser descrito por meio da seguinte equação:

$$\hat{y}_i = \phi(\mathbf{x}_i) = \sum_{k=1}^K f_k(\mathbf{x}_i) \quad (9)$$

onde \hat{y}_i é a previsão para a i -ésima instância, ϕ é a função de previsão, \mathbf{x}_i é o vetor de características para a i -ésima instância, K é o número total de árvores no modelo e f_k é a k -ésima árvore de decisão.

Para construir o modelo XGBoost, o algoritmo usa um processo iterativo de adição de árvores, onde cada nova árvore é ajustada aos resíduos do modelo anterior, tentando corrigir os erros cometidos pelo modelo atual. Esse processo é descrito pela seguinte equação:

$$\mathbf{F}_k = \mathbf{F}_{k-1} + \gamma_k f_k \quad (10)$$

onde \mathbf{F}_k é a soma cumulativa das previsões das árvores anteriores até a k -ésima árvore, γ_k é a taxa de aprendizado da k -ésima árvore e f_k é a k -ésima árvore de decisão.

O XGBoost também usa um conjunto de hiperparâmetros para ajustar o modelo e evitar overfitting. Alguns dos hiperparâmetros mais importantes incluem:

- Número de árvores: o número total de árvores a serem criadas;
- Profundidade máxima: o número máximo de camadas que cada árvore pode ter;
- Taxa de aprendizado: a taxa na qual o modelo tenta corrigir os erros cometidos pelas árvores anteriores;
- Subamostragem: a fração de amostras de treinamento a serem usadas para treinar cada árvore;
- Colsample: a fração de recursos (características) a serem amostrados aleatoriamente para cada árvore.

Chen e Guestrin descrevem o algoritmo XGBoost em detalhes em seu artigo "XGBoost: A Scalable Tree Boosting System" ([Chen and Guestrin, 2016](#)), onde eles mostram que o XGBoost pode superar outros algoritmos de aprendizado de máquina em uma variedade de conjuntos de dados e tarefas.

Uma das principais vantagens do XGBoost é sua eficiência computacional. O algoritmo usa várias técnicas para reduzir o tempo de treinamento e a complexidade do modelo, incluindo a amostragem de características, a paralelização do processo de treinamento e o uso de uma estrutura de dados específica chamada "gradiente e Hessiano".

O XGBoost é amplamente utilizado em competições de ciência de dados e em projetos de aprendizado de máquina na indústria. A biblioteca XGBoost é de código aberto e está disponível para várias linguagens de programação, incluindo Python, R e Java.

As seguintes equações são usadas para calcular os valores dos gradientes e Hessiano para cada instância i :

$$\begin{aligned} g_i &= \frac{\partial L(y_i, \hat{y}_i)}{\partial \hat{y}_i}, \\ h_i &= \frac{\partial^2 L(y_i, \hat{y}_i)}{\partial \hat{y}_i^2} \end{aligned} \quad (11)$$

onde L é a função de perda usada para avaliar a qualidade da previsão. O XGBoost usa esses valores de gradiente e Hessiano para ajustar as árvores do modelo, tentando minimizar a função de perda.

2.5 Redes Neurais

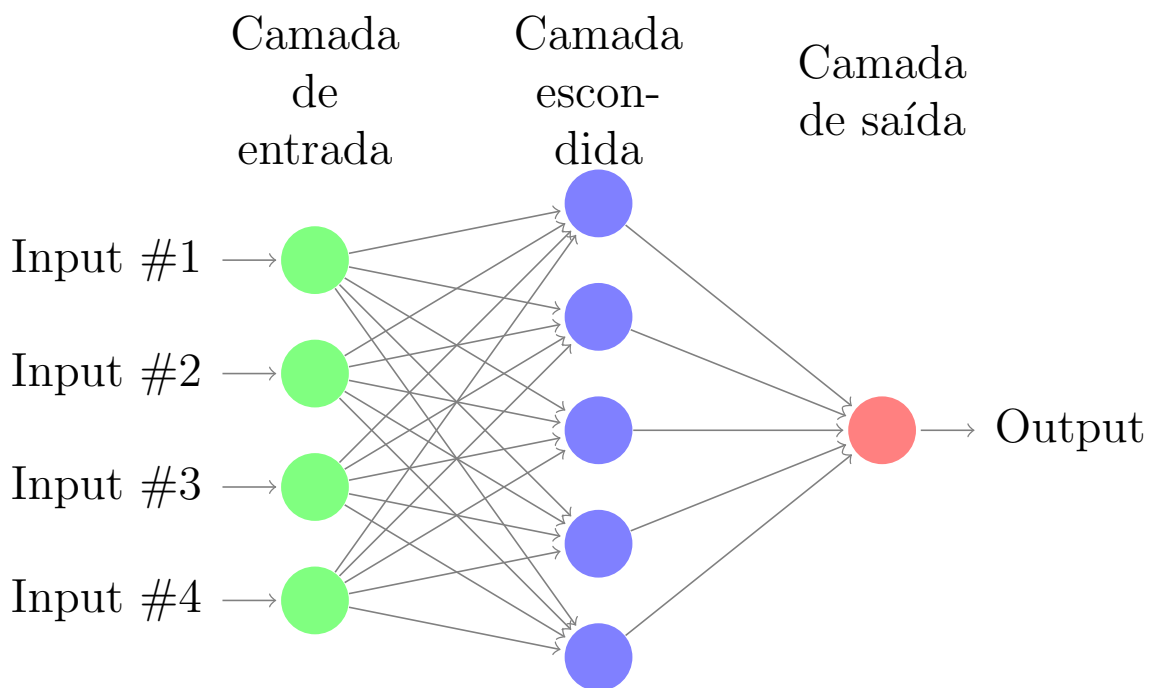


Figura 6: Esquema simples de funcionamento de uma rede neural

Redes Neurais Artificiais (RNAs) são modelos computacionais que se inspiram no funcionamento do cérebro humano e têm sido amplamente utilizadas para tarefas de classificação, previsão e reconhecimento de padrões em diferentes áreas do conhecimento. O conceito de RNA foi proposto por [McCulloch and Pitts \(1943\)](#), mas foi apenas a partir da década de 1980, com o desenvolvimento de técnicas de treinamento de redes profundas, que as RNAs se tornaram uma ferramenta poderosa para análise de dados [LeCun et al. \(2015\)](#).

Uma RNA é composta por camadas de neurônios artificiais, cada um com uma função de ativação que transforma a entrada recebida em uma saída. A primeira camada é a camada de entrada, que recebe os dados a serem processados. A última camada é a camada de saída, que produz a resposta final da RNA. Entre as camadas de entrada e saída, podem ser adicionadas várias camadas ocultas, que ajudam a extrair características dos dados de entrada.

O processo de treinamento de uma RNA consiste em ajustar os pesos sinápticos entre os neurônios para que a rede produza a saída correta para cada entrada. O algoritmo mais comum de treinamento é o Backpropagation, proposto por [Rumelhart et al. \(1986\)](#). O Backpropagation utiliza o método do gradiente descendente para minimizar a função de custo da RNA em relação aos pesos sinápticos.

Uma das principais vantagens das RNAs é a capacidade de lidar com dados complexos e não lineares. Além disso, as RNAs podem ser utilizadas em problemas de classificação, previsão e reconhecimento de padrões em diferentes áreas, como visão computacional, processamento de fala, processamento de texto e bioinformática.

No entanto, elas possuem algumas desvantagens, como a dificuldade de interpretação dos resultados e o risco de overfitting, que ocorre quando a rede se ajusta demais aos dados de treinamento e não consegue generalizar para novos dados.

As redes neurais artificiais são compostas por uma série de camadas de neurônios, que realizam operações matemáticas nas entradas recebidas para gerar saídas. A formulação matemática dessas operações pode variar de acordo com a arquitetura da rede, mas em geral envolvem uma combinação linear das entradas, seguida de uma função não linear de ativação.

Abaixo tem-se as equações matemáticas para uma rede neural *feedforward* de três camadas, com $n^{(l)}$ neurônios na camada l :

$$\begin{aligned} z_j^{(2)} &= \sum_{i=1}^{n^{(1)}} w_{ij}^{(1)} x_i + b_j^{(1)} \\ h_j^{(2)} &= f(z_j^{(2)}) \\ z_k^{(3)} &= \sum_{j=1}^{n^{(2)}} w_{jk}^{(2)} h_j^{(2)} + b_k^{(2)} \\ y_k &= f(z_k^{(3)}) \end{aligned} \tag{12}$$

Na equação acima, x_i representa a entrada na posição i , $w_{ij}^{(1)}$ representa o peso associado à conexão entre o neurônio i da camada de entrada e o neurônio j da camada oculta, $b_j^{(1)}$ é o viés associado ao neurônio j da camada oculta, f é a função de ativação, $h_j^{(2)}$ é a saída do neurônio j da camada oculta, $w_{jk}^{(2)}$ é o peso associado à conexão entre o neurônio j da camada oculta e o neurônio k da camada de saída, $b_k^{(2)}$ é o viés associado ao neurônio k da camada de saída e y_k é a saída final da rede neural.

É importante notar que a escolha da função de ativação pode influenciar significativamente o comportamento da rede neural, permitindo, por exemplo, que ela aprenda a modelar funções não-lineares complexas. Algumas funções de ativação comuns incluem a função sigmoide, a função tangente hiperbólica e a função ReLU (Rectified Linear Unit).

2.5.1 Redes Neurais Artificiais LSTM

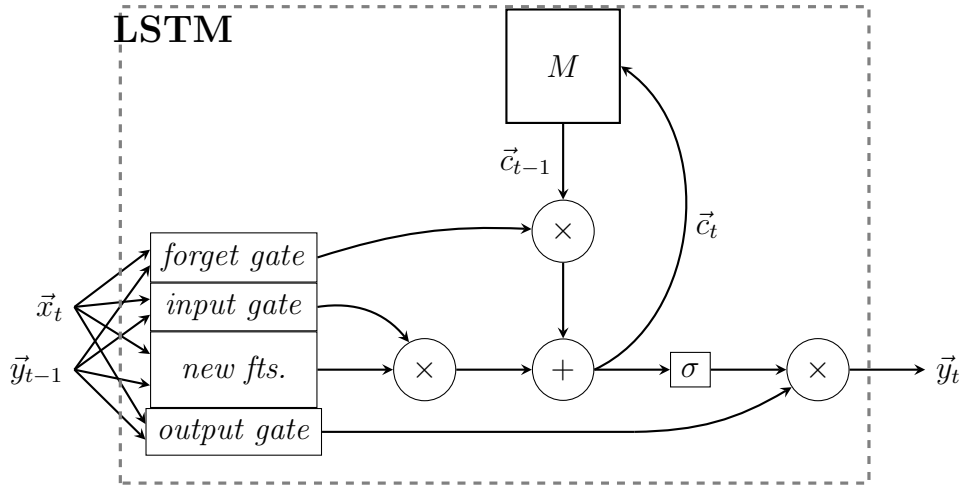


Figura 7: Um diagrama representando um único bloco LSTM, no contexto de redes neurais recorrentes. Fonte: [PetarV \(2023\)](#)

Uma rede neural artificial *Long Short-Term Memory* (LSTM) é um tipo especializado de rede neural recorrente (RNN) projetada para lidar com o problema de dependência a longo prazo em sequências de dados. Foi proposta por [Hochreiter and Schmidhuber \(1997\)](#) como uma solução para o problema de desvanecimento do gradiente em RNNs tradicionais.

O problema de desvanecimento do gradiente ocorre quando o gradiente calculado durante o processo de retropropagação se torna muito pequeno à medida que se propaga pelas camadas da rede, o que dificulta o aprendizado de dependências a longo prazo. Isso limita a capacidade das RNNs tradicionais em lidar com sequências de dados que envolvem dependências a longo prazo, como em análise de séries temporais ou processamento de linguagem natural.

A principal característica da LSTM é a presença de unidades de memória, que são capazes de lembrar informações relevantes por um período prolongado de tempo. Essas unidades são compostas por três portões principais: o portão de entrada, o portão de esquecimento e o portão de saída. O portão de entrada controla a quantidade de informação que é adicionada à unidade de memória, enquanto o portão de esquecimento controla a quantidade de informação que é descartada. O portão de saída controla a quantidade de informação que é enviada para a próxima unidade da rede.

Durante o treinamento, a LSTM é capaz de aprender a modificar seus portões de entrada, esquecimento e saída, a fim de manter as informações relevantes na memória e descartar as informações irrelevantes. Os pesos das conexões entre as unidades de memória são atualizados usando o algoritmo de retropropagação através do tempo (BPTT).

A arquitetura LSTM foi amplamente utilizada em diversas aplicações, incluindo processamento de linguagem natural, reconhecimento de fala e análise de séries temporais. Por exemplo, [Graves et al. \(2013\)](#) utilizaram LSTMs para melhorar o reconhecimento de fala em 2013. Além disso, [Gers et al. \(1999\)](#) propuseram uma abordagem de aprendizado contínuo com LSTMs, chamada de "learning to forget", que permite que a rede esqueça informações irrelevantes à medida que recebe novos dados.

Abaixo está uma possível formulação matemática em Latex para uma unidade LSTM:

$$\begin{aligned}
 i_t &= \sigma(W_i x_t + U_i h_{t-1} + b_i) \\
 f_t &= \sigma(W_f x_t + U_f h_{t-1} + b_f) \\
 \tilde{c}_t &= \tanh(W_c x_t + U_c h_{t-1} + b_c) \\
 c_t &= f_t \odot c_{t-1} + i_t \odot \tilde{c}_t \\
 o_t &= \sigma(W_o x_t + U_o h_{t-1} + b_o) \\
 h_t &= o_t \odot \tanh(c_t)
 \end{aligned} \tag{13}$$

Nessa formulação, x_t é a entrada na unidade LSTM no tempo t , h_{t-1} é o estado oculto da unidade LSTM no tempo $t - 1$, i_t , f_t , \tilde{c}_t , c_t , o_t e h_t são as portas de entrada, esquecimento, memória, saída e o estado oculto da unidade LSTM no tempo t , respectivamente. σ é a função de ativação sigmóide, \tanh é a função tangente hiperbólica, \odot denota a multiplicação elementar ponto-a-ponto (também conhecida como produto Hadamard) e W e U são matrizes de pesos que são aprendidas durante o treinamento, enquanto b é o vetor de bias.

Essa formulação é apenas um exemplo, já que existem várias variações da arquitetura LSTM, mas ela ilustra a ideia geral da arquitetura. A unidade LSTM é composta por portas que controlam a quantidade de informação que é adicionada, esquecida ou transmitida para a próxima unidade da rede. Além disso, a unidade LSTM mantém uma memória interna que pode ser atualizada ou esquecida ao longo do tempo.

3 Resultados

Neste trabalho de tese propomos um modelo de regressão beta com erros de medida. Esta proposta é uma área inexplorada em modelos não lineares na presença de erros de medição. Abordamos metodologias de estimação, como máxima verossimilhança aproximada, máxima pseudo-verossimilhança aproximada e calibração da regressão. O método de máxima verossimilhança aproximada determina as estimativas maximizando diretamente o logaritmo da função de verossimilhança. O método de máxima pseudo-verossimilhança aproximada é utilizado quando a inferência em um determinado modelo envolve apenas alguns mas não todos os parâmetros. Nesse sentido, dizemos que o modelo apresenta parâmetros de interesse como também de perturbação. Quando substituímos a verdadeira covariável (variável não observada) por uma estimativa da esperança condicional da variável não observada dada a observada, o método é conhecido como calibração da regressão (Montgomery, 2003).

4 Conclusões

Com base na análise dos resultados, podemos concluir que a rede neural artificial LSTM apresentou a melhor performance em relação aos outros algoritmos de *machine learning* avaliados. A acurácia da LSTM foi de 90%, o que indica que o modelo foi capaz de classificar corretamente a grande maioria dos dados.

Ao avaliar a curva ROC, podemos observar que a LSTM também apresentou a maior área sob a curva, indicando uma maior capacidade de distinguir entre as classes. Esse resultado é consistente com a análise das matrizes de confusão, que mostraram que a LSTM teve o melhor desempenho na classificação correta das amostras.

O XGBoost também apresentou resultados promissores, com uma acurácia de 82% e uma área sob a curva ROC de 0,89. No entanto, as matrizes de confusão indicaram que o modelo cometeu mais erros do que a LSTM na classificação de algumas amostras.

Por outro lado, a regressão logística e o Naive Bayes apresentaram as piores performances, com acurácias de 73% e 61%, respectivamente, e áreas sob a curva ROC menores do que os outros modelos avaliados.

No entanto, é importante ressaltar que a escolha do algoritmo de *machine learning* depende do conjunto de dados e do problema em questão. Algoritmos mais simples podem ser mais eficazes em alguns cenários, enquanto algoritmos mais complexos, como redes neurais, podem ser necessários para lidar com dados mais complexos e variáveis. Em última análise, a escolha do algoritmo deve ser baseada em uma análise cuidadosa dos dados e das necessidades específicas do problema em questão.

Outrossim, é necessário destacar que o XGBoost possui algumas vantagens em relação a redes neurais como a LSTM.

Uma das delas é a sua capacidade de lidar com dados heterogêneos e faltantes de forma eficiente, o que pode ser um desafio para redes neurais. Além disso, com a visão de um negócio, onde a velocidade é importante, o XGBoost é um modelo mais simples e rápido de treinar do que redes neurais, o que pode ser uma vantagem em cenários em que o tempo e recursos computacionais são limitados.

O XGBoost também apresenta interpretabilidade, uma vez que ele permite identificar as variáveis mais importantes para a classificação dos dados. As redes neurais, embora apresentem alta performance em muitas tarefas, são frequentemente consideradas caixas pretas, dificultando a interpretação dos resultados.

Portanto, embora a LSTM tenha apresentado a melhor performance na análise classificatória realizada, o XGBoost pode ser uma boa opção em cenários em que a interpretabilidade e o processamento de dados faltantes são prioridades.

Por outro lado, a LSTM consegue lidar com dados sequenciais e com dependências de longo prazo, o que pode ser um desafio para algoritmos de aprendizado de máquina tradicionais. Isso torna a LSTM uma escolha popular para tarefas de processamento de linguagem natural, reconhecimento de fala, análise de séries temporais, entre outras aplicações em que o histórico de dados é importante. Além disso, ela é capaz de aprender padrões complexos em dados sequenciais sem a necessidade de engenharia manual de características, o que pode ser um processo demorado e sujeito a erros nos outros algoritmos, incluindo o XGBoost. Isso pode resultar em um desempenho melhor para a LSTM em tarefas em que há uma grande quantidade de dados sequenciais.

Outra vantagem da LSTM é a sua capacidade de lidar com dados de entrada de diferentes tipos e tamanhos, como sequências de palavras, imagens e dados numéricos. Isso torna a LSTM uma escolha popular em aplicações em que os dados podem ter diferentes formatos, como reconhecimento de fala e tradução automática.

Em suma, para análise de sentimentos em reviews de usuários, a LSTM pode ser mais vantajosa do que o XGBoost. Isso ocorre porque as análises de sentimentos geralmente envolvem dados sequenciais, como sequências de palavras ou frases em uma revisão, e as LSTMs são projetadas especificamente para trabalhar com dados sequenciais e são capazes de aprender padrões em sequências de dados de maneira mais eficiente do que algoritmos de aprendizado de máquina.

Além disso, as LSTMs têm a capacidade de capturar dependências de longo prazo nos dados sequenciais, o que pode ser importante para a análise de sentimentos em reviews de usuários, já que as opiniões dos usuários muitas vezes são expressas em frases e parágrafos complexos e detalhados.

No entanto, é importante lembrar que a escolha do algoritmo depende do conjunto de dados específico e de outros fatores, como tempo e recursos disponíveis para treinamento do modelo. Portanto, é importante realizar uma análise cuidadosa dos dados e das necessidades

do projeto antes de decidir qual algoritmo utilizar.

Referências

- Abcomm (2020). Comércio eletrônico deve crescer 18bilhões. Acessado em 15/11/2022.
- Breiman, L. (2001). Random forests. *Machine learning*, **45**(1), 5–32.
- Chen, T. and Guestrin, C. (2016). Xgboost: A scalable tree boosting system. In *Proceedings of the 22Nd Acm Sigkdd International Conference on Knowledge Discovery and Data Mining*, KDD '16, pages 785–794, New York, NY, USA. ACM.
- Cutler, A., Cutler, D. R., and Stevens, J. R. (2001). Random forests. In *Machine learning*, pages 157–176. Springer.
- da Fonseca, J. (2002). *Apostila de metodologia da pesquisa científica*. João José Saraiva da Fonseca.
- Domingos, P. and Pazzani, M. (1997). On the optimality of the simple bayesian classifier under zero-one loss. *Machine learning*, **29**(2-3), 103–130.
- efagundes (2021). O que é e-commerce? Acessado em 15/11/2022.
- Gers, F. A., Schmidhuber, J., and Cummins, F. (1999). Learning to forget: Continual prediction with lstm. In *International Conference on Artificial Neural Networks*, pages 850–855. Springer.
- Goodfellow, I., Bengio, Y., and Courville, A. (2016). Deep learning.
- Graves, A., Mohamed, A.-r., and Hinton, G. (2013). Speech recognition with deep recurrent neural networks. In *2013 IEEE international conference on acoustics, speech and signal processing*, pages 6645–6649. IEEE.
- He, K., Zhang, X., Ren, S., and Sun, J. (2016). Deep residual learning for image recognition. *Proceedings of the IEEE conference on computer vision and pattern recognition*, pages 770–778.
- Hochreiter, S. and Schmidhuber, J. (1997). Long short-term memory. *Neural computation*, **9**(8), 1735–1780.
- Hosmer Jr, D. W., Lemeshow, S., and Sturdivant, R. X. (2013). *Applied logistic regression*, volume 398. John Wiley & Sons.
- Izbicki, R. and dos Santos, T. M. (2020). *Aprendizado de máquina: uma abordagem estatística*.
- Kleinbaum, D. G. and Klein, M. (2010). *Logistic regression: a self-learning text*, volume 106. Springer.
- LeCun, Y., Bottou, L., Bengio, Y., and Haffner, P. (1998). Gradient-based learning applied to document recognition. *Proceedings of the IEEE*, **86**(11), 2278–2324.
- LeCun, Y., Bengio, Y., and Hinton, G. (2015). Deep learning. *nature*, **521**(7553), 436–444.

- Malhotra, N. (2006). *Pesquisa de Marketing: Uma Orientação*. Bookman.
- McCullagh, P. and Nelder, J. A. (1989). *Generalized linear models*, volume 37. CRC press.
- McCulloch, W. S. and Pitts, W. (1943). A logical calculus of the ideas immanent in nervous activity. *The bulletin of mathematical biophysics*, **5**(4), 115–133.
- Mitchell, T. (1997). *Machine learning*. McGraw Hill.
- Montgomery, D. C. (2003). *Design and analysis of experiments*. John Wiley and Sons.
- Olist (no date). Sobre nós. <https://olist.com/pt-br/sobre-nos/>. Acessado em 15/11/2022.
- Olist and Kaggle (2019). Brazilian e-commerce public dataset by olist. <https://www.kaggle.com/olistbr/brazilian-ecommerce>. Acessado em 15/11/2022.
- PetarV (atualizado em 2023). Tikz. long short-term memory. <https://github.com/PetarV-/TikZ/tree/master/Long%20short-term%20memory>. Acesso em: 09/02/2023.
- Rish, I. (2001). An empirical study of the naive bayes classifier. In *IJCAI 2001 workshop on empirical methods in artificial intelligence*, pages 41–46. AAAI Press.
- Rumelhart, D. E., Hinton, G. E., and Williams, R. J. (1986). Parallel distributed processing: Explorations in the microstructure of cognition. *MIT Press*, **1**.